

PPGEEC2327 – Tópicos Especiais em Processamento Inteligente da Informação

Inteligência artificial aplicada à geofísica

Capítulo 1 — Introdução ao aprendizado de máquina em geosciências

Baseado em Schuster, G.T. — *Machine Learning Methods in Geoscience*

Professor: Tiago Barros

Programa de Pós-graduação em Engenharia Elétrica e de Computação (PPgEEC) — UFRN

Sumário da Aula

Introdução

Três Ondas Históricas das Redes Neurais

Três Classes de Aprendizado de Máquina

Aprendizado Supervisionado

Aprendizado Não Supervisionado

Aprendizado por Reforço

Síntese e Fechamento

Introdução

O que é Aprendizado de Máquina?

Definição

Definição de Arthur Samuel (cientista da IBM, anos 1950):

“Aprendizado de máquina é o campo de estudo que dá aos computadores a capacidade de aprender sem serem explicitamente programados.”


- Muitos métodos de ML ajustam uma relação **não linear** entre dados de entrada e saída — equivalente a uma regressão não linear.
- Diferença fundamental: a relação entrada-saída **não é programada explicitamente** (ex.: soma ponderada de polinômios de ordem fixa) — o programa **aprende** a função de ajuste a partir dos dados.
- Dezenas de algoritmos: SVM, PCA, redes neurais recorrentes, *clustering*, detecção de objetos, redes convolucionais, entre outros (Bishop, 2006).

Nota terminológica

“Aprendizado profundo” (*deep learning*) normalmente se refere a redes convolucionais com **mais de 5 camadas** (Goodfellow et al., 2016).

Três Ondas Históricas das Redes Neurais

75 Anos de Metamorfoses do Aprendizado de Máquina



- **Cibernética** (1940s–1960s, Wiener 1948): estudo científico de como humanos, animais e máquinas controlam e se comunicam.
- Modelo biológico do neurônio (McCulloch & Pitts, 1943; Hebb, 1949) → **perceptron** (Rosenblatt, 1958).


O Modelo do Perceptron

Sinal de entrada x_i relacionado à saída y por:

$$y = \sigma\left(\sum_i w_i x_i + b\right)$$

- w_i : peso do sinal de entrada x_i
- b : termo de viés (*bias*)
- $\sigma(z) = \frac{1}{1 + e^{-z}}$: função sigmoide
- Perceptron original: função tudo-ou-nada $\sigma(z) = \text{sinal}(z)$.
- Substituída por funções suaves (deriváveis em todo ponto), como a sigmoide.

Função sigmoide (“squashing”)



Ideia-Chave

A sigmoide “espreme” (*squashes*) sua saída para o intervalo $(0, 1)$ para $-\infty < z < \infty$.

O Mark 1 Perceptron (IBM)

- Concebido como **máquina** (não programa), implementado em hardware customizado.
- Câmera com array de 20×20 fotocélulas $\rightarrow$ imagem de 400 pixels.
- Pesos codificados em potenciômetros; atualizações via motores elétricos.
- Projetado para **reconhecimento de imagens**.

Controvérsia histórica (1958)

Coletiva de imprensa da Marinha dos EUA: o *New York Times* noticiou o perceptron como “embrião de um computador eletrônico” que um dia “andaria, falaria, veria, escreveria, se reproduziria e teria consciência de sua existência”.

Interpretação biológica: um sinal elétrico x é transmitido pela sinapse ao neurônio vizinho se a voltagem de entrada exceder um limiar.

O Mark 1 Perceptron (IBM)




Figure 1.3: Mark 1 IBM computer for image recognition. Left photo: the camera system in which an input scene is recorded by a 20×20 array of cadmium sulphide photocells to give an image with 400 pixels. Middle photo: the perceptron consisted of a patch board which allowed different configurations of input features to be tried. Right photo: racks of adaptive weights where the weight values were adjusted automatically by the learning algorithm. Images from Bishop (2006).

De Perceptrons a Redes Neurais

Generalizando para M neurônios recebendo um vetor de entrada $N \times 1$:

$$y_i = \sigma \left(\sum_{j=1}^N w_{ij} x_j + b_i \right)$$

- Saída $M \times 1$: vetor $\mathbf{y}$; pesos formam a matriz $M \times N$: $\mathbf{W}$.
- σ atua elemento a elemento sobre $\mathbf{z} = \mathbf{W}\mathbf{x} + \mathbf{b} \rightarrow$ vetor de saída $\mathbf{y}$ (ou vetor de **ativação** $\mathbf{a}$, se camada oculta).



Ascensão, Queda e Ressurgimento

Queda (meados dos anos 1990)

- Custo computacional alto.
- Incapacidade de prever teoricamente o desempenho.
- Foco migra para métodos matematicamente tratáveis (ex.: SVM).

Ressurgimento (1998+)

- **Redes Convolucionais (CNN)** — LeCun et al. (1998); base em Fukushima (1980), Wang (1988, 1990).
- Matrizes **esparsas** (convolução) substituem matrizes densas → redes profundas viáveis.
- Rebatização como **Deep Learning**.

Ideia-Chave

Multiplicador de força: GPUs baratas aceleram as operações convolucionais → explosão de aplicações (Facebook, Google, carros autônomos).

Três Classes de Aprendizado de Máquina

Panorama: Três Classes de ML

Entrada $\mathbf{x}^{(n)} \rightarrow$ Pesos $\mathbf{W} \rightarrow$ Saída $\mathbf{y}^{(n)}$

Supervisionado
 $(\mathbf{x}^{(n)}, \mathbf{y}^{(n)})$ dados
Encontrar $\mathbf{W}$

Não Supervisionado
 $(\mathbf{x}^{(n)}, ?)$
Encontrar padrões/estrutura

Por Reforço
 $(\mathbf{x}^{(n)}, \text{recompensa})$
Encontrar $\mathbf{W}$

- Aplicações em sismica de exploração: análise de reservatório, processamento e interpretação sísmica.
- Método supervisionado mais usado hoje em geociências: **redes neurais convolucionais** (Cap. 9).

Aprendizado Supervisionado

Definição

Procedimento para encontrar um modelo (ex.: coeficientes de $\mathbf{W}$) que prediz a saída $\mathbf{y}$ a partir da entrada $\mathbf{x}$, usando um **conjunto de treinamento** de muitos pares $(\mathbf{x}^{(n)}, \mathbf{y}^{(n)})$ — muito mais pares que pesos desconhecidos em $\mathbf{W}$.


Exemplo

Classificar imagens como “cachorro” ou “não cachorro”:

- Imagem $N \times N \rightarrow$ vetor achatado $\mathbf{x}^{(n)} \in \mathbb{R}^{N^2}$.
- Rótulo escalar: $y = 1$ (cachorro) ou $y = 0$ (não cachorro).
- Muitos pares de treino $\rightarrow$ sistema **sobredeterminado**.
- $\mathbf{W}$ estimado por otimização iterativa (Caps. 4–6).

Exemplo: Classificação de Lâminas de Calcário (*limestone*)

- Entrada: imagens coloridas de lâminas (*thin sections*) de rochas.
- **Esqueletização**: histogramas RGB $\rightarrow$ variância, obliquidade (*skewness*) e curtose de cada canal de cor.
- Saída: 7 classes de tipo dominante de geologia (definidas por geólogo).



Ideia-Chave

Resultado: matriz de confusão mostra acurácia **superior a 90%** na classificação de lâminas fora do conjunto de treino (Patel et al., 2016).

Exemplo: Classificação de Lâminas de Calcário (*limestone*)




Figure 1.6: Neural network for classifying thin sections (Patel et al., 2016).

Semi-supervisionado

- Poucos dados **rotulados**, muitos dados **não rotulados**.
- Rotular mais dados é caro (Patel et al., 2016).

Fracamente supervisionado

- Cada imagem recebe **um** rótulo (classe dominante), mas o objetivo é rotular no nível de **pixel**.
- Ex.: seção sísmica rotulada como “domo de sal” mesmo contendo outras estruturas.

Ideia-Chave

Objetivo do *representation learning*: desemaranhar os fatores de variação que compõem a aparência de uma imagem.

Aprendizado Não Supervisionado

Definição

Os dados de treino **não especificam** o vetor-alvo y ; o objetivo é separar padrões distintos presentes na entrada x .

Exemplo

Registro sísmico (*common shot gather*): ondas Rayleigh (superfície) e ondas-P guiadas (GW) aparecem **emaranhadas** no domínio tempo-distância, mas **bem separadas** no domínio velocidade de fase $\times$ frequência ($C-f$), pois propagam com velocidades muito diferentes.

- Outros exemplos: separação sinal/ruído por **PCA** (Cap. 16), *clustering* (Cap. 17), análise discriminante por Modelo de Mistura Gaussiana (Cap. 21).





Figure 1.7: a). Common shot gather (CSG) of seismic data and b) phase velocity (ω/k) versus frequency ($f = \omega/2\pi$) plot of the CSG. Here, the Rayleigh surface waves (SW) and P-wave guided waves (GW) are now well separated after a temporal Fourier transform and a Radon transform (Li et al., 2018).

Aprendizado por Reforço

Definição

Treina um agente por **tentativa e erro**: a saída não é uma classe rotulada, mas a **recompensa** por vencer/progredir em uma tarefa.



Processo de Decisão de Markov:

- Conjunto S de estados do ambiente e do agente.
- Conjunto A de ações;
 $P(s, s') = \Pr(s_{t+1} = s' \mid s_t = s, a_t = a)$.
- $R_a(s, s')$: recompensa imediata pela transição de s para s' com ação a .

RL: Supervisionado ou Não Supervisionado?

Um meio-termo

RL usa um pequeno conjunto de dados rotulados para **iniciar** o treinamento, depois usa um conjunto muito maior de dados não rotulados, aprendendo o melhor comportamento que **maximiza a recompensa**.

- Também conhecido como **programação dinâmica aproximada** (pesquisa operacional, teoria de controle).
- Estudado em economia como **teoria dos jogos**.

Exemplo

Xadrez: o jogador novato aprende com erros passados (ex.: não sacrificar um bispo por um peão), antecipando contra-jogadas do oponente.

Filhote andando: tentativa e erro leva à capacidade de se alimentar — a recompensa é crescer mais forte.

Estudar para provas: tentativa e erro revela que resolver exercícios (não só ler) leva à compreensão profunda.


Ma e Luo (2018) — picking automático de tempos de trânsito por RL:

- Calculam razões de energia em janelas ao longo das primeiras chegadas.
- Mapa de recompensa: razão de energia da janela atual vs. estados anteriores.
- Agente maximiza a recompensa cumulativa descontada esperada.

Ideia-Chave

Shingling: primeiras chegadas caracterizadas por saltos abruptos no tempo de trânsito — desafio para o *picking* automático.

RL em Geociências: Picking de Primeiras Chegadas



Síntese e Fechamento

- ML busca **padrões** nos dados e aprende com a experiência a reconhecê-los em dados novos.
- Um algoritmo bem treinado pode analisar volumes de dados ordens de magnitude **mais rápido** que equipes de geocientistas.
- **Não supervisionado**: menos custoso, mas menos capaz (sem dados rotulados).
- **Supervisionado**: preferido na prática — domina exploração sísmica, dados de satélite, sismologia, geoquímica, campos potenciais.

Obrigado!

Perguntas e discussão