

PPGEEC2327 – Tópicos Especiais em Processamento Inteligente da Informação

Inteligência artificial aplicada à geofísica

Capítulo 2 — Predição de dados por inversão de mínimos quadrados

Baseado em Schuster, G.T. — *Machine Learning Methods in Geoscience*

Professor: Tiago Barros

Programa de Pós-graduação em Engenharia Elétrica e de Computação (PPgEEC) — UFRN

Sumário da Aula

Motivação e Formulação do Problema

Exemplo Motivador: a Motocicleta

Solução por Mínimos Quadrados

Regularização

Interpretação Geométrica do Gradiente

Pré-condicionamento

Sobreajuste (*Overfitting*)

Otimização por Descida do Gradiente

Otimização Não Linear e Método de Newton

Síntese e Fechamento

Motivação e Formulação do Problema

O Problema Geral de Inversão

Objetivo

Encontrar o modelo $\mathbf{w}$ que **melhor prediz** os dados-alvo $\mathbf{t}$ a partir dos dados de entrada $\mathbf{X}$.

$$\mathbf{X}\mathbf{w} = \mathbf{t}$$

- Em geral esse sistema é **sobredeterminado**, **inconsistente** e **mal-condicionado**.
- Não existe solução exata $\Rightarrow$ buscamos o modelo ótimo $\mathbf{w}^*$ que minimiza o erro de predição

$$\epsilon = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{t}\|^2 \quad (\text{norma } L_2).$$

- Regularização e pré-condicionadores $\rightarrow$ atenuam mal-condicionamento, inconsistência e não linearidade.
- Método direto é caro para sistemas grandes $\rightarrow$ usamos **otimização por gradiente** (iterativa).

Inversão geofísica geral

- $\mathbf{t}$: medidas físicas reais (ex.: gravimetria)
- $\mathbf{X}$ não linear, governado por física newtoniana (ex.: EDP)

Por que começar por mínimos quadrados?

Todo o arcabouço de otimização por gradiente usado em redes neurais profundas (Caps. 3-13) nasce exatamente daqui.

Classificação por redes neurais

- Elementos de $\mathbf{t}$ restritos a poucas classes
- Ex.: gato $\rightarrow (t_1, t_2) = (1, 0)$; cachorro $\rightarrow (0, 1)$
- Sem lei física: $\mathbf{w}$ é extraído de padrões em $(\mathbf{X}, \mathbf{t})$

Exemplo Motivador: a Motocicleta

Exemplo Motivador: Velocidade da Motocicleta

a) Road next to Bonneville Salt Flats



b) Suggestion



c) Great Gravel Road to Great Salt Lake




Figure 2.1: Pictures taken on GTS motorcycle trip in Utah's West Desert with views of a) Bonneville Salt Flat region, b) wildlife sign, and c) the Great Salt Lake.

Exemplo Motivador: Velocidade da Motocicleta

- Estimar a lentidão (*slowness*) $w = t/x$ de uma moto em uma estrada de cascalho de 5 km.
- Tempo t_i medido a cada 1 km percorrido x_i .
- Modelo linear hipotético: $x_i w = t_i$

$$\underbrace{\begin{bmatrix} 0 \\ 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}}_x w = \underbrace{\begin{bmatrix} 0 \\ 0.102 \\ 0.33 \\ 0.50 \\ 0.80 \end{bmatrix}}_t$$

(Dados = amostra; repetir em outro local $\rightarrow$ conjunto de treinamento)



Sistemas Sobredeterminados, Inconsistentes e Mal-condicionados

- $Xw = t$ é $M \times N$ com $M = 5$ equações e $N = 1$ incógnita.
- **Sobredeterminado:** $M > N$.
- **Inconsistente:** não há solução comum — a 2ª linha dá $w = 0.102$, a 3ª dá $w = 0.165$.
- **Mal-condicionado:** se $w_1 + 10^{-3}w_2 = t \Rightarrow \delta w_2 = 10^3 \delta t$
 - pequenos erros nos dados $\rightarrow$ grandes mudanças no modelo.

Definição

A **derivada de Fréchet** $\delta t / \delta w_i$ mede a sensibilidade do dado t a mudanças no i -ésimo parâmetro do modelo.

Aplicação geofísica: *tomografia de tempo de trânsito* (inversão de velocidade a partir de tempos de chegada).

Solução por Mínimos Quadrados


A Função Objetivo

Minimizamos a soma dos resíduos ao quadrado:

$$\epsilon = \frac{1}{2}(\mathbf{X}\mathbf{w} - \mathbf{t})^T(\mathbf{X}\mathbf{w} - \mathbf{t}) = \frac{1}{2}\mathbf{w}^T\mathbf{X}^T\mathbf{X}\mathbf{w} - \mathbf{t}^T\mathbf{X}\mathbf{w} + \frac{1}{2}\mathbf{t}^T\mathbf{t} = \frac{1}{2}\sum_{i=1}^M r_i^2$$

onde $\mathbf{r} = \mathbf{X}\mathbf{w} - \mathbf{t}$ é o vetor resíduo $M \times 1$.

- $N = 1$: $\epsilon(w)$ é uma **parábola**.
- $N = 2$: $\epsilon(\mathbf{w})$ é uma **tigela** de erro.
- $N > 2$: superfície quádrlica em $N-1$ dimensões.



A Função Objetivo




Figure 2.3: Misfit function and contours for the quadratic polynomial $\epsilon = w_1^2 + w_2^2 + 40$, where the red dot is directly below the global minimum at $\mathbf{w}^* = (w_1^*, w_2^*)$. The gradient $\nabla\epsilon = (\frac{\partial\epsilon}{\partial w_1}, \frac{\partial\epsilon}{\partial w_2})$ points along the steepest uphill direction and is perpendicular to the contour tangent. See exercises [2.5.3](#)-[2.5.6](#).

Condição de Estacionariedade e Gradiente

No mínimo global $\mathbf{w}^*$, o gradiente é nulo:

$$\left. \frac{\partial \epsilon}{\partial w_k} \right|_{\mathbf{w}=\mathbf{w}^*} = 0, \quad \forall k$$

Derivando explicitamente:

$$\nabla \epsilon_k = \frac{\partial \epsilon}{\partial w_k} = \sum_{i=1}^M x_{ik} \left(\sum_{n=1}^N x_{in} w_n - t_i \right) = [\mathbf{X}^T (\mathbf{X} \mathbf{w} - \mathbf{t})]_k$$

Igualando a zero $\Rightarrow$ **equações normais**:

$$\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{t}$$

Solução de Mínimos Quadrados

$$\mathbf{w} = [\mathbf{X}^T \mathbf{X}]^{-1} \mathbf{X}^T \mathbf{t}$$

minimiza a soma dos resíduos ao quadrado.

Exemplo

Para o exemplo da moto, $N = 1$:

$$\frac{\partial \epsilon}{\partial w} = \sum_{i=1}^5 x_{i1}(x_{i1}w - t_i) = 0 \implies w = \frac{\sum_i x_{i1} t_i}{\sum_i x_{i1}^2} = 0.182 \text{ h/km}$$

Ponto estacionário $w^* = 0.182 \text{ h/km} \implies \text{velocidade média} \approx 5.5 \text{ km/h}$.

Interpretação geométrica: as equações normais dizem que o vetor de tempos preditos $\mathbf{X}\mathbf{w}^*$ é perpendicular ao resíduo $\mathbf{X}\mathbf{w}^* - \mathbf{t}$.

Regularização

Por que Regularizar?

Se houver erro de temporização δt_i em cada estação:

$$w = \underbrace{\frac{\sum_i x_{i1} t_i^0}{\sum_i x_{i1}^2}}_{w_0} + \underbrace{\frac{\sum_i x_{i1} \delta t_i}{\sum_i x_{i1}^2}}_{\delta w}$$

Problema

Se as distâncias x_{i1} são muito pequenas, o denominador $\rightarrow 0$ e $|\delta w| \gg 0$: erros de dados são **amplificados**.


Solução: somar termo de regularização (amortecimento) $\eta > 0$:

$$w = \frac{\sum_i x_{i1} t_i}{\sum_i x_{i1}^2 + \eta}$$

η tipicamente 1%–5% do maior elemento diagonal de $\mathbf{X}^T \mathbf{X}$.

Custo: perda de precisão na solução final.

Ideia-Chave: Curvatura Pequena $\Rightarrow$ Número de Condição Grande



$$\frac{\partial^2 \epsilon}{\partial w^2} = \sum_{i=1}^M x_{i1}^2 \approx 0 \text{ se } |x_{i1}| \approx 0 \forall i$$

Ideia-Chave

Autovalores de $\mathbf{X}^T \mathbf{X}$: $\mathbf{X}^T \mathbf{X} \mathbf{x}_i = \lambda_i \mathbf{x}_i$.

Se o número de condição $|\lambda_{\max}/\lambda_{\min}| > 10^4$, o sistema deve ser regularizado — pequenos erros δt são muito amplificados nas direções de λ_i pequeno.

Derivação Rigorosa da Solução Regularizada

Função objetivo = ajuste aos dados + penalidade do modelo:

$$\epsilon = \underbrace{\frac{1}{2}(\mathbf{X}\mathbf{w} - \mathbf{t})^T(\mathbf{X}\mathbf{w} - \mathbf{t})}_{\text{desajuste}} + \underbrace{\frac{1}{2}\eta \mathbf{w}^T \mathbf{w}}_{\text{penalidade}}$$

Anulando o gradiente $\Rightarrow$ **equações normais regularizadas**:

$$[\mathbf{X}^T \mathbf{X} + \eta \mathbf{I}] \mathbf{w} = \mathbf{X}^T \mathbf{t}$$

$$\boxed{\mathbf{w} = [\mathbf{X}^T \mathbf{X} + \eta \mathbf{I}]^{-1} \mathbf{X}^T \mathbf{t}}$$

- η grande $\rightarrow$ soluções próximas da origem, maior desajuste $\|\mathbf{r}\|^2$.
- Também chamada de **mínimos quadrados amortecidos** (*damped least squares*).


Interpretação Geométrica do Gradiente

O Gradiente Aponta na Direção de Máxima Subida

Expandindo $\epsilon(\mathbf{w})$ em série de Taylor em torno de $\mathbf{w}_o$:

$$\epsilon(\mathbf{w}) - \epsilon(\mathbf{w}_o) = \nabla \epsilon(\mathbf{w}_o)^T \Delta \mathbf{w}$$

- Se $\Delta \mathbf{w}$ está sobre o mesmo contorno $\Rightarrow \nabla \epsilon \perp$ tangente do contorno.
- $-\nabla \epsilon$ aponta na direção de **descida mais íngreme** (*steepest descent*).



Se $\mathbf{w}'$ prediz $\mathbf{t}'$ (não os dados reais $\mathbf{t}$), com $\mathbf{X}\mathbf{w}' = \mathbf{t}'$, então:

$$\Delta \mathbf{w} = \mathbf{w}^* - \mathbf{w}' = [\mathbf{X}^T \mathbf{X}]^{-1} \mathbf{X}^T \underbrace{(\mathbf{t} - \mathbf{t}')}_{\Delta \mathbf{t}}$$

Fórmula de atualização de Gauss-Newton (não linear):

$$\mathbf{w}^* = \mathbf{w}' + [\mathbf{X}^T \mathbf{X}]^{-1} \mathbf{X}^T \Delta \mathbf{t}$$

Importância

Esta é a fórmula que dá origem a *todos* os métodos de descida por gradiente estudados nos próximos capítulos (redes neurais, CNNs, etc.).


Pré-condicionamento

Pré-condicionamento

Para $N = 2$: $\epsilon = aw_1^2 + bw_2^2$ (contornos elípticos).

$$\mathbf{X} = \begin{bmatrix} a^{1/2} & 0 \\ 0 & b^{1/2} \end{bmatrix}$$

Se $|a^{1/2}| \gg |b^{1/2}|$: mal-condicionado (vales estreitos).



Pré-condicionador diagonal:

$$\mathbf{C} = \begin{bmatrix} a^{-1/2} & 0 \\ 0 & b^{-1/2} \end{bmatrix} \Rightarrow \mathbf{CXw} = \mathbf{Ct}$$

$\mathbf{CX} = \mathbf{I}$: autovalores unitários, número de condição = 1 $\Rightarrow$ contornos circulares!

Pré-condicionamento: Forma Geral

Para as equações normais:

$$\mathbf{C}[\mathbf{X}^T \mathbf{X}] \mathbf{C}^{-1} \mathbf{C} \mathbf{w} = \mathbf{C} \mathbf{X}^T \mathbf{t}$$

- Escolher $\mathbf{C}$ tal que o número de condição de $\mathbf{C}[\mathbf{X}^T \mathbf{X}] \mathbf{C}^{-1}$ seja pequeno.
- Também reduz o condicionamento agrupando (*clustering*) os autovalores.
- Uso comum: **escalonamento** (*scaling*) — normalizar cada linha de $\mathbf{X}$.

Ideia-Chave

Em redes neurais (Cap. 9), pré-condicionamento = normalizar dados de entrada com unidades/variações distintas, garantindo contribuição balanceada de cada tipo de dado.

Sobreaajuste (*Overfitting*)


Aumentando a Complexidade do Modelo

Modelo quadrático: $t = w_1x + w_2x^2$

- Ajuste muito melhor: $\sim 1/7$ do erro do modelo linear.
- Mas $P > M$ (mais parâmetros que equações)
 $\Rightarrow$ sistema **subdeterminado**.
- Erro $\rightarrow 0$, mas o modelo passa a ajustar o **ruído**, não o sinal.

Sobreajuste

O modelo não generaliza bem para novos dados.



Teste de Sanidade: Treino / Validação / Teste



1. Calcula-se $\mathbf{w}_P$ ótimo (dados de **treino**) para cada ordem P do polinômio.
2. Erro de **validação** indica o melhor P (nem sub- nem sobreajustado).
3. **Teste** (*holdout*) avalia de forma não-viesada o modelo final escolhido.



Termo de Viés (*Bias*)

Se o relógio tem erro sistemático $\Delta\tau$ no instante inicial:

$$t = w_0 + w_1 x$$

$$\underbrace{\begin{bmatrix} 1 & x_{11} \\ 1 & x_{21} \\ \vdots & \vdots \\ 1 & x_{51} \end{bmatrix}}_x \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = t$$

- w_0 modela retas que não passam pela origem.
- Análogo a um **modelo inicial** de baixo número de onda em inversão sísmica (evita *cycle-skipping*).
- Redes neurais (Caps. 4, 5) sempre incluem um termo de viés para deslocar a entrada da função de ativação.

Otimização por Descida do Gradiente

Do Gauss-Newton à Descida Mais Íngreme (*Steepest Descent*)

Fórmula iterativa de Gauss-Newton:

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - [\mathbf{X}^T \mathbf{X}]^{-1} \mathbf{X}^T \Delta \boldsymbol{\tau}^{(k)}$$

A inversa de $\mathbf{X}^T \mathbf{X}$ é cara $\rightarrow$ aproximar por sua **diagonal**:

$$w_i^{(k+1)} = w_i^{(k)} - \alpha \frac{1}{[\mathbf{X}^T \mathbf{X}]_{ii}} (\mathbf{X}^T \Delta \boldsymbol{\tau}^{(k)})_i$$

- α : comprimento do passo (*step length*), obtido por busca linear.
- Diferente do caso linear, geralmente **não converge em uma única iteração**.

Algoritmo de Descida do Gradiente

1. Inicializar $k = 0$, chute inicial $\mathbf{w}^{(0)}$. Calcular $\mathbf{t}^{(0)} = \mathbf{X}\mathbf{w}^{(0)}$, resíduo $\Delta\boldsymbol{\tau}^{(0)}$.
2. Atualizar $\mathbf{w}^{(k+1)}$ com passo α (ex.: fixo, ou **Adagrad**: $\alpha = \alpha_0 / \sqrt{\sum (g_i^{(\kappa)})^2 + \eta}$).
3. Recalcular resíduo. Se $\|\mathbf{r}^{(k+1)}\|$ pequeno, parar; senão $k := k + 1$, repetir.

Versão **regularizada e pré-condicionada**:

$$w_i^{(k+1)} = w_i^{(k)} - \alpha \frac{1}{[\mathbf{X}^T \mathbf{X}]_{ii}} (\mathbf{X}^T \Delta\boldsymbol{\tau}^{(k)} + \eta \mathbf{w}^{(k)})_i$$

Código MATLAB: Descida Mais Íngreme

```
1 H = X'*X;
2 for i = 1:100
3     g = X'*(X*w - t);           % gradiente
4     alpha = g'*g/(g'*H*g);       % comprimento de passo exato
5     w = w - alpha*g;            % atualizacao do modelo
6     r = X*w - t;                % residuo
7     if r'*r <= .0001; i = 100; end
8 end
```

onde $\mathbf{H} = \mathbf{X}^T \mathbf{X}$ (Hessiana) e $\alpha = \frac{\mathbf{g}^T \mathbf{g}}{\mathbf{g}^T \mathbf{H} \mathbf{g}}$ é o passo **exato** para uma função quadrática (ver Apêndice 2.6).

Atenção

Passo exato só funciona bem para problemas **lineares**. Redes neurais e FWI são não lineares $\Rightarrow$ Cap. 3.

Descida Simples vs. Pré-condicionada




Figure 2.9: Iterative solutions to equation 2.42 by the a) steepest descent and b) preconditioned steepest descent methods.

Sistema exemplo $\mathbf{X}\mathbf{w} = \mathbf{t}$ (Eq. 2.42 do texto), 4 equações, 2 incógnitas.

Otimização Não Linear e Método de Newton

Operador linear f satisfaz:

$$f(w_1 + w_2) = f(w_1) + f(w_2) \quad f(\alpha w) = \alpha f(w)$$

- Funções **não lineares**, ex.: $f(w) = w_1^4 - 10w_2 + 4x$, podem ter **múltiplos mínimos**.
- Um método de gradiente iterativo pode ficar preso em um **mínimo local**.

Consequência prática

A mesma fórmula de descida se aplica, mas $\mathbf{X}^{(k)}$ agora depende da iteração — é reavaliada a cada passo.

Método de Newton (Caso 1D)

Expansão em série de Taylor de $f(w)$ em torno de w_o , truncada em 2ª ordem:

$$f(w) \approx f(w_o) + \frac{\partial f(w_o)}{\partial w} \Delta w + \frac{1}{2} \frac{\partial^2 f(w_o)}{\partial w^2} \Delta w^2$$

Igualando $\partial f / \partial w = 0$ e isolando Δw :

$$w^{(k+1)} = w^{(k)} - \alpha \frac{\partial f(w^{(k)}) / \partial w}{\partial^2 f(w^{(k)}) / \partial w^2}$$

- Convergência depende da curvatura e inclinação em $w^{(k)}$.
- Diferente da parábola: a curvatura da função quártica **varia** com w .

Exemplo 1D: $f(w) = aw^4 + w^2 - 2w$

```
1 a = 7;
2 w = -1.5;           % ponto inicial
3 for it = 2:10
4     f1prime = a*4*w^3+2*w-2;
5     f2prime = a*12*w^2+2;
6     w = w - f1prime/f2prime; % Newton
7     ww(it) = w;
8 end
```

Exemplo 1D: $f(w) = aw^4 + w^2 - 2w$




Figure 2.10: Plot of a) quartic function and b) residual vs iteration curve. The diamond (square) represents the starting (ending) model.

Losango = ponto inicial; quadrado = ponto final (mínimo local encontrado).

Método de Newton em N Dimensões: Função de Rosenbrock

$$f(\mathbf{w}) = 100(w_2 - w_1^2)^2 + (1 - w_1)^2 \quad \text{mínimo global em } (1, 1)$$
$$\mathbf{g} = \begin{bmatrix} -400w_1(w_2 - w_1^2) - 2(1 - w_1) \\ 200(w_2 - w_1^2) \end{bmatrix}, \quad \mathbf{H} = \begin{bmatrix} 1200w_1^2 - 400w_2 + 2 & -400w_1 \\ -400w_1 & 200 \end{bmatrix}$$
$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \mathbf{H}^{-1}\mathbf{g}$$

Método de Newton em N Dimensões: Função de Rosenbrock




Figure 2.11: (Top) Contours of the Rosenbrock function, where the global minimum at $(w_1, w_2) = (1, 1)$ is indicated by the red star. Lower plot depicts Newton iterates converging to the true minimum within 10 iterations; results computed by the MATLAB code [2.3.2](#).

Síntese e Fechamento

Resumo do Capítulo

- Sistemas $\mathbf{X}\mathbf{w} = \mathbf{t}$ mal-condicionados, inconsistentes, sobredeterminados.
- Solução regularizada minimiza **desajuste** + **penalidade**: η controla o compromisso.
- Termo de viés $\rightarrow$ desloca a origem (*bulk shift*).
- Custo direto $O(N^3)$ (via $[\mathbf{X}^T \mathbf{X} + \eta \mathbf{I}]^{-1}$) $\rightarrow$ métodos iterativos custam $O(KN^2)$, $K \ll N$.
- Sobreajuste: modelo ajusta ruído, não sinal $\rightarrow$ dividir dados em treino/validação/teste.
- Pré-condicionamento: acelera convergência via reescalonamento.
- Gauss-Newton $\rightarrow$ descida mais íngreme $\rightarrow$ (regularizada + pré-condicionada) $\rightarrow$ base de todo otimizador de redes neurais.

Obrigado!

Perguntas e discussão