

PPGEEC2327 – Tópicos Especiais em Processamento Inteligente da Informação

Inteligência artificial aplicada à geofísica

Capítulo 5 — Processamento de dados geofísicos com redes neurais totalmente conectadas

Baseado em Schuster, G.T. — *Machine Learning Methods in Geoscience*

Professor: Tiago Barros

Programa de Pós-graduação em Engenharia Elétrica e de Computação (PPgEEC) — UFRN

Introdução

Filtragem de Imagens de Migração

Filtragem no Domínio do Ângulo

Filtragem de Ondas de Superfície

Síntese e Fechamento

Introdução

- Cap. 4 apresentou a teoria das FCNNs; agora aplicamos a dados geofísicos reais.
- Três estudos de caso neste capítulo:
 1. Filtragem de artefatos em imagens de **migração sísmica** (domínio $x-z$).
 2. Filtragem de imagens de migração no **domínio do ângulo** (ADCIG).
 3. Isolamento do **modo fundamental** de ondas de superfície (domínio $k-\omega$).


Ideia-Chave

Em todos os casos: FCNN (ou SVM, Cap. 7) aprende a separar **signal** de **ruído** a partir de características **esqueletizadas** (*skeletonized features*) extraídas dos dados brutos.

Filtragem de Imagens de Migração

O Problema: Ruído em Imagens de Migração

- Migração sísmica estima a refletividade $m(\mathbf{z})$, $\mathbf{z} = (x, z)$, a partir dos dados registrados na superfície.
- Alguns valores de amplitude são **artefatos** do método de migração (*aliasing*), não refletores reais.
- Objetivo: treinar uma FCNN para distinguir **ruído** de **sinal** pixel a pixel.



Definição

Imagem de migração 201×201 pixels ($N = 40.401$); apenas **70 pixels** (0,17% da imagem) são rotulados manualmente para treino.

Características Esqueletizadas (*Skeletonized Features*)

Em uma janela deslizante 5×5 centrada no pixel i , calculam-se três características:


- θ_i : **ângulo de mergulho** dominante (*dip*) via *slant stack* local.
- ϕ_i : **coerência** da migração (soma ao longo do eixo de offset/ângulo).
- A_i : **amplitude do envelope** (via transformada de Hilbert).

Ideia-Chave

Intuição física: artefatos de migração têm coerência **fraca**, mergulho **grande** e amplitude **fraca**; o sinal de reflexão tem coerência **forte**, mergulho **modesto** e amplitude **forte**.

$$\mathbf{x}^{(i)} = (1, \theta_i, \phi_i, A_i), \quad y^{(i)} = \begin{cases} 1 & \text{sinal} \\ 0 & \text{ruído} \end{cases}$$

Características Esqueletizadas (*Skeletonized Features*)




- **Regressão logística:** 1 camada oculta, 1 nó (equivalente a um único neurônio sigmoide).
- **NN de 2 camadas:** camada oculta com **15 nós**, ativação sigmoide em todas as camadas.
- Treino sobre os 70 pixels rotulados $(\theta_i, \phi_i, A_i, y_i)$.

Ideia-Chave


A **superfície de decisão** (plano ou hipersuperfície amarela no espaço de características) separa pixels rotulados $y = 1$ (sinal) de $y = 0$ (ruído). Inferência aplica essa fronteira aos pixels não rotulados.

Arquiteturas Testadas e Superfície de Decisão

a) One-Layer Neural Network




b) Two-layer Neural Network



Inferência e Filtragem por Mutaç o (*Muting*)

1. **Treino**: encontrar pesos W que separam corretamente os 70 pixels rotulados.
2. **Infer ncia**: classificar **todos** os pixels da imagem (fora do conjunto de treino).
3. **Muta  o**: pixels classificados como ru do t m sua amplitude suprimida (*muting*).







Regressão logística vs. NN de 2 camadas

Ambos os métodos produzem imagens filtradas **muito similares** neste exemplo — a fronteira de decisão para 15 nós não trouxe grande vantagem porque a amplitude forte já distinguia bem ruído de sinal.

Enriquecendo o Modelo: Termos Não Lineares

Em vez de um modelo linear $\mathbf{w}^T \mathbf{x}$, podemos expandir o vetor de características:

$$\mathbf{x} = (1, x_1, x_2, x_3, x_1^2, x_2^2, x_3^2, x_1x_2, x_1x_3, x_2x_3) \quad (10 \times 1)$$



Enriquecendo o Modelo: Termos Não Lineares

- Fronteira de decisão adquire **mais curvatura** (comparado ao vetor 4×1 anterior).
- Comparação com **SVM de kernel gaussiano** (Cap. 7): fronteira ao longo de superfície não linear.
- Resultado prático: pouca diferença nas imagens filtradas finais para este exemplo — amplitude forte já era o principal discriminante.

Ideia-Chave

Dados sísmicos reais raramente são tão bem comportados: a escolha das características esqueletizadas certas é o verdadeiro desafio prático.

Filtragem no Domínio do Ângulo

Motivação: Mergulhos Conflitantes

Limitação da filtragem em (x, z)


Quando sinal e ruído **se cruzam** no espaço (x, z) (mergulhos conflitantes), mutar o ruído também pode eliminar sinal útil.

- **Solução:** transformar os dados para um domínio onde sinal e ruído se **separam** espacialmente.
- **ADCIG** (*Angle-Domain Common Image Gather*): *slant stack* local aplicado a $m(H, x, z) \rightarrow \tilde{m}(\theta, x, z)$.
- Filtrar (mutar) no domínio θ e depois **transformar de volta** para (x, z) .

Definição

Neste caso, usa-se **SVM** (Cap. 7) em vez de FCNN — capacidade equivalente demonstrada na seção anterior.

Migration Filtering Workflow



- Pixels rotulados como ruído são **mutados** no domínio ADCIG.
- Transformada **inversa**: volta ao domínio (x, z) com artefatos removidos.

Exemplo

Chen et al. (2020): aplicado a dados sintéticos com espaçamento de traços de 100 m e 200 m — artefatos de *aliasing* **largamente eliminados** em ambos os casos.





Aplicação a Dados Marinhos Reais (Mar do Norte)

- Fatia vertical de imagem de migração 3D.
- Kernel gaussiano no SVM.
- Artefatos aparecem como interfaces **irregulares** (*jittery*) em profundidades rasas ($0 < z < 1,5$ km).


Ideia-Chave

Resultado: filtragem SVM **elimina em grande parte** as interfaces espúrias rasas, preservando os refletores reais mais profundos.

Aplicação a Dados Sintéticos (*Marmousi*)



Aplicação a Dados Marinhos Reais (Mar do Norte)



Filtragem de Ondas de Superfície

Motivação: Inversão de Ondas Rayleigh

- Ondas Rayleigh no registro sísmico (*common shot gather*) $d(x, t)$ podem ser invertidas para estimar o modelo de velocidade $S, v_s(x, z)$.
- Velocidade aparente de propagação das ondas Rayleigh $\approx$ média ponderada de v_s até $\sim 1/3$ a $1/2$ do comprimento de onda.
- Estratégia de inversão:
 - Selecionar a curva de dispersão fundamental $\kappa(\omega)$ no espectro $\tilde{D}(k, \omega)$.
 - Invertê-la para obter $v_s(x, z)$.
- **Problema:** modos de ordem superior interferem no *picking* automático da curva de dispersão **fundamental**.

Motivação: Inversão de Ondas Rayleigh




Figure 5.8: a) True S-velocity layer model, b) a shot gather and c) the frequency spectrum of the raw shot gather. The Rayleigh waves in the CSG are the strongest amplitude arrivals denoted as the dark red-blue events which intersect the time axis at around 0.3 s and the offset of 120 m. From Li et al. (2020).

Definição

Curva de dispersão: $\kappa(\omega)$ no domínio k - ω , ou velocidade de fase $C(\omega) = \omega/\kappa(\omega)$.

Estratégia: Janela Automática no Domínio $k-\omega$

- Transformar $d(x, t) \xrightarrow{\text{Fourier 2D}} \tilde{D}(k, \omega)$.
- Treinar uma NN para definir uma **janela** que isola a energia do modo fundamental.
- Mutar toda energia **fora** da janela $\rightarrow$ facilita o *auto-picking* de $\kappa(\omega)$.




Figure 5.9: Common shot gather $d(x,t)$ on the left and the fundamental ($n=0$) dispersion curves for Love waves in the (top right) $k-\omega$ and (bottom right) $C(\omega)-\omega$ domains. Here the phase velocity is $C(\omega) = \omega/\kappa(\omega)$ and $\kappa(\omega)$ is the picked dispersion curve, i.e. the skeletonized data (Li et al., 2017).

Três Características Esqueletizadas do Espectro

Coerência
amplitude local


Ângulo de mergulho
via *slant stack*

Faixa de frequência
mapa f por pixel


Ideia-Chave

A fronteira do modo fundamental tem mergulho **suave** em baixas frequências (5–12 Hz) e **íngreme** em altas frequências (30–80 Hz) — correlação frequência-mergulho que a NN aprende a reconhecer, assim como um intérprete humano.

Três Características Esqueletizadas do Espectro




Fluxo de Trabalho Completo



- Pixel na janela do modo fundamental $\rightarrow$ rotulado $y = 1$; fora da janela $\rightarrow y = 0$.
- **Superfície de decisão:** fronteira encontrada por inspeção no espaço de características.
- **Inferência:** aplicar a espectros de novos tiros (não rotulados) para isolar o modo fundamental.





Fluxo de Trabalho Completo







Comparação de Quatro Modelos de Classificação Binária

- Regressão logística (1 nó).
- NN de 1 camada, 10 nós.
- SVM com kernel gaussiano.
- NN de 2 camadas: 50 nós (1^a) + 25 nós (2^a).





Comparação de Quatro Modelos de Classificação Binária



Comparação de Quatro Modelos de Classificação Binária



Comparação de Quatro Modelos de Classificação Binária



Síntese e Fechamento

Resumo do Capítulo

- Três estudos de caso mostraram FCNNs (e SVMs) aplicadas a **dados geofísicos reais**: migração (x, z) , migração em domínio de ângulo (ADCIG) e ondas de superfície (k, ω) .
- Estratégia comum: **esqueletizar** os dados brutos em poucas características discriminativas (coerência, mergulho, amplitude, faixa de frequência).
- Às vezes é melhor **transformar o domínio** dos dados (ex.: ADCIG, $k-\omega$) antes de filtrar, para separar espacialmente sinal e ruído.
- Modelos simples (regressão logística) e complexos (NN de 2 camadas, SVM) frequentemente têm desempenho **semelhante** quando as características são bem escolhidas.

Lição central

O verdadeiro desafio não é o algoritmo de ML em si, mas a **escolha inteligente** de como abordar o problema — requer intuição física, experiência e tentativa e erro.

Obrigado!

Perguntas e discussão