

PPGEEC2327 – Tópicos Especiais em Processamento Inteligente da Informação

Inteligência artificial aplicada à geofísica

Capítulo 7 — Máquinas de vetores de suporte (SVM)

Baseado em Schuster, G.T. — *Machine Learning Methods in Geoscience*

Professor: Tiago Barros

Programa de Pós-graduação em Engenharia Elétrica e de Computação (PPgEEC) — UFRN

Sumário da Aula

Introdução

Teoria do SVM: Margem e Vetores de Suporte

SVM Linear

SVM Não Linear

Soluções Primal e Dual

O Truque do Kernel

Exemplo Numérico: Filtragem de Migração

SVM Multiclasse

Hinge-Loss e Margem Suave

Questões Práticas de Implementação

Síntese e Fechamento

Introdução

O que é uma Máquina de Vetores de Suporte?

Definição

SVM (*Support Vector Machine*, Cortes & Vapnik, 1995) é um método de aprendizado supervisionado que classifica dados binários em duas classes.

- Mesmo objetivo da regressão logística ou de uma NN, mas **mais simples**: não exige o desenho de uma arquitetura de rede.
- Para dados linearmente separáveis, o SVM linear **sempre converge** — livre de mínimos locais.
- Pode ser generalizado para múltiplas classes e para regressão (SVR).
- Popularidade crescente nas últimas duas décadas em biomedicina, sensoriamento remoto, geofísica.

- Classificação de perfis de poço (*well-log*)
- Filtragem de imagens de migração (Cap. 5)
- Filtragem de ondas de superfície (Cap. 5)
- Inversão AVO
- Interpolação e inversão de traços sísmicos
- Classificação de eventos sísmicos (sismologia)
- *Picking* de tempos de trânsito
- Identificação de falhas em seções sísmicas
- Interpretação de litofácies (multiclasse)


Ideia-Chave

Vantagem central: o SVM não requer um conjunto de treino gigante — basta conter os **vetores de suporte** relevantes.

Teoria do SVM: Margem e Vetores de Suporte

O Problema: Encontrar a Melhor Linha Separadora

- Dados de treino $(\mathbf{x}^{(n)}, y^{(n)})$, $y^{(n)} = \pm 1$.
- Muitas retas separam as classes $+$ e $-$ — qual é a **melhor**?
- **Melhor reta**: tracejada preta, com a maior margem (**mais espessa**) $2d$, equidistante das duas classes.
- Os pontos tocados pela margem são os **vetores de suporte**.



$$w^T x + b = 0 \quad (\text{reta de decisão}), \quad w^T x + b = \pm 1 \quad (\text{margens})$$

Distância Perpendicular ao Hiperplano

Distância de um ponto $\mathbf{x}^{(n)}$ ao plano


$\hat{\mathbf{w}}^T \mathbf{x} + \tilde{b} = 0$:

$$\tilde{d} = \frac{1}{\|\mathbf{w}\|} |\mathbf{w}^T \mathbf{x}^{(n)} + b|$$

Eliminando o valor absoluto com $y^{(n)} = \pm 1$:

$$\tilde{d} = \frac{1}{\|\mathbf{w}\|} y^{(n)} (\mathbf{w}^T \mathbf{x}^{(n)} + b)$$

Positivo sempre que $\mathbf{x}^{(n)}$ é classificado corretamente.



SVM Linear

Formulação do Problema Primal

Maximizar a margem sujeita à separação correta:

$$(\mathbf{w}^*, b^*) = \arg \max_{\mathbf{w}, b} \left\{ \frac{1}{\|\mathbf{w}\|} \min_{\mathbf{x}^{(n)}} [y^{(n)}(\mathbf{w}^T \mathbf{x}^{(n)} + b)] \right\}, \quad \text{s.a. } y^{(n)}(\mathbf{w}^T \mathbf{x}^{(n)} + b) > 0$$

Fixando o valor mínimo em 1 para os vetores de suporte ($y^{(n)}(\mathbf{w}^T \mathbf{x}_{\text{supp}}^{(n)} + b) = 1$), o problema equivale a:

$$(\mathbf{w}^*, b^*) = \arg \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{s.a. } y^{(n)}(\mathbf{w}^T \mathbf{x}^{(n)} + b) \geq 1 \quad \forall \mathbf{x}^{(n)}$$


Ideia-Chave

Transformamos um problema de **maximização** de $1/\|\mathbf{w}\|$ em um problema de **minimização** de $\|\mathbf{w}\|^2$ — mais conveniente algoritmicamente (programação quadrática).

SVM Não Linear

Quando uma Reta Não Basta

- Dados não linearmente separáveis (ex.: uma classe cercada pela outra).
- Solução: transformação não linear $\mathbf{z} = \phi(\mathbf{x})$ para um espaço de **maior dimensão**.
- Exemplo: $(x_1, x_2) \rightarrow (z_1, z_2, z_3) = (x_1, x_2, \sqrt{x_1^2 + x_2^2})$.
- No espaço $\mathbf{z}$, um **plano** $z_3 = 1$ separa as classes.



Definição

Problema Primal (Ideia-Chave 7.4.1): encontrar $(\tilde{\mathbf{w}}^*, \tilde{b}^*) = \arg \min \frac{1}{2} \|\tilde{\mathbf{w}}\|^2$ sujeito a $y^{(n)}(\tilde{\mathbf{w}}^T \mathbf{z}^{(n)} + \tilde{b}) \geq 1$.

Custo da Transformação Não Linear

- Resolver o problema primal transformado por inversão direta custa $O(D_z^3)$, onde D_z é a dimensão do espaço transformado — o mesmo custo de inverter a matriz normal $\mathbf{X}^T \mathbf{X}$ (Cap. 2).
- Após encontrar $(\tilde{\mathbf{w}}^*, \tilde{b}^*)$, um novo ponto $\mathbf{x}$ é classificado transformando-o para $\mathbf{z}$ e verificando o sinal de $\tilde{\mathbf{w}}^T \mathbf{z} + \tilde{b}$.

Custo

Se a dimensão de $\mathbf{z}$ aumenta por um fator 4, o custo $O(D^3)$ vira $O(4^3 D^3)$ — caro para D grande.

Soluções Primal e Dual

O Problema Dual: Lagrangiano

Problema primal: custo $O(D^3)$, caro para $D \gg 1$. Alternativa: resolver o **problema dual**.

Definição

Encontrar $\mathbf{w}$, b que minimizam e α que maximiza o Lagrangiano:

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{n=1}^N \alpha_n (y^{(n)} (\mathbf{w}^T \mathbf{x}^{(n)} + b) - 1), \quad \alpha_n \geq 0$$

- N = número de restrições = número de vetores de treino (não D).
- $\alpha_n = 0$ para não-vetores de suporte; $\alpha_n \neq 0$ apenas para vetores de suporte.
- Benefício-chave: no espaço dual, o **truque do kernel** se torna possível (próxima seção).

Lagrangiano Reduzido

Anulando $\partial L / \partial w_i = 0$ e $\partial L / \partial b = 0$:

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y^{(n)} \mathbf{x}^{(n)}, \quad \sum_{n=1}^N \alpha_n y^{(n)} = 0$$

Substituindo de volta, obtemos o **Lagrangiano reduzido** — apenas em função de α :

$$L(\alpha) = \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N y^{(n)} y^{(m)} \alpha_n \alpha_m \mathbf{x}^{(n)T} \mathbf{x}^{(m)} \quad \text{s.a. } \alpha_n \geq 0, \quad \alpha^T \mathbf{y} = 0$$

Ideia-Chave

Agora só há N incógnitas (α_n) — muito mais eficiente quando $D \gg N$ (ex.: imagens médicas com milhões de pixels por exame).

O Truque do Kernel

Da Matriz de Gram ao Truque do Kernel

O Lagrangiano reduzido no espaço $\mathbf{z}$ requer apenas produtos internos $\mathbf{z}^{(n)T} \mathbf{z}^{(m)}$:

$$y^{(n)} y^{(m)} \mathbf{z}^{(n)T} \mathbf{z}^{(m)} \rightarrow y^{(n)} y^{(m)} k(\mathbf{x}^{(n)}, \mathbf{x}^{(m)})$$

- Se $y_i = 1 \ \forall i$: matriz $N \times N$ de produtos é a **matriz de Gram**.
- **Truque do kernel**: especificar diretamente $k(\mathbf{x}, \mathbf{x}') = \mathbf{z}(\mathbf{x})^T \mathbf{z}(\mathbf{x}')$, sem nunca construir $\mathbf{z}$ explicitamente.
- Essencial quando $\mathbf{z}$ tem dimensão **muito alta ou infinita**.

Exemplo

Kernel Gaussiano: $k(\mathbf{x}, \mathbf{x}') = e^{-\|\mathbf{x} - \mathbf{x}'\|^2 / \sigma^2}$ — fácil de calcular mesmo quando $\mathbf{z}(\mathbf{x})$ tem dimensão infinita.

Kernel	Fórmula
Linear	$\mathbf{x}^T \mathbf{x}'$
Polinomial de ordem p	$(\mathbf{x}^T \mathbf{x}' + 1)^p$
Gaussiano (RBF)	$e^{-\gamma \ \mathbf{x} - \mathbf{x}'\ ^2}$
Rede neural de 2 camadas	$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}' + \beta_1)$

Exemplo Numérico: Filtragem de Migração


Revisitando o Cap. 5: SVM na Filtragem de Migração

- Janela 5×5 centrada no pixel i : 3 características esqueletizadas (θ_i, ϕ_i, A_i) — mergulho, coerência, amplitude.
- Usuário rotula pixels do conjunto de treino como sinal ou ruído.
- Menos de 100 pixels rotulados de uma imagem 201×201 ($< 0,2\%$).
- Comparação: regressão logística, NN de 2 camadas, SVM Gaussiano (com e sem regularização).

Ideia-Chave

Resultado (Chen et al.): SVM Gaussiano **sem** regularização teve o melhor desempenho, capturando mergulhos íngremes que a regularização tendia a excluir.

SVM na Filtragem de Migração



SVM Multiclasse

Estendendo para Múltiplas Classes: Um-contra-Todos

- Estratégia mais usada: **um-contra-todos** (*one-versus-all*).
- Para K classes: treinar K classificadores binários, cada um separando a classe k do restante.

Desafios

- Pode gerar classificações **inconsistentes** (um ponto atribuído a mais de uma classe — resolvido escolhendo a classe de maior valor predito).
- **Dados desbalanceados**: classe minoritária deve receber peso maior.

Ideia-Chave


Pesos sugeridos: classe minoritária com peso $+1$; demais classes com peso $1/(K - 1)$.

Hinge-Loss e Margem Suave

Função de Perda *Hinge* (Dobradiça)

Para lidar com erros de classificação, adiciona-se regularização à função objetivo:

$$\epsilon = \lambda \|\mathbf{w}\|^2 + \frac{1}{N} \sum_{n=1}^N \gamma(z^{(n)}), \quad \gamma(z^{(n)}) = \max(0, 1 - y^{(n)}(\mathbf{w}^T \mathbf{x}^{(n)} + b))$$



- $\lambda \approx 0$: margem **fina**, poucos erros tolerados (equivalente ao SVM de margem rígida).
- $\lambda \gg 0$: margem **larga**, mais erros tolerados — margem **suave**.

Questões Práticas de Implementação

Escalonamento

- Características com unidades/escalas diferentes dominam a métrica de distância.
- Padronização: $\hat{x}_i = (x_i - \bar{x})/\sigma$.
- Normalização: $\hat{x}_i = \frac{x_i - \bar{x}}{\max(x_i) - \min(x_i)}$.

Aumento de dados

- *Dropout*: evita *overfitting*.
- + dados corrompidos: pesos mais robustos.
- Balanceamento: sobreamostrar a classe minoritária (ex.: gerar amostras sintéticas na fronteira entre vizinhos).

Custo Computacional: Primal vs. Dual

Problema	Custo	Melhor quando
Primal (mínimos quadrados regularizado)	$O(ND^2 + D^3)$	$N > D$
Dual (matriz de Gram)	$O(DN^2 + N^3)$	$D > N$
Otimização por gradiente (m iterações)	$O(mN^2)$, $m \ll N$	Problemas muito grandes

Quando o SVM fica caro demais

Se N e D são ambos grandes, restringir o treino a pontos com alta probabilidade de serem vetores de suporte, ou preferir NN/CNN.

Síntese e Fechamento

SVM vs. Rede Neural: Prós e Contras

Vantagens do SVM

- Converge ao mínimo **global** (sem mínimos locais).
- Poucos hiperparâmetros (kernel, C).
- Funciona bem com **poucos dados** de treino.
- Não depende de inicialização aleatória.

Vantagens da NN

- Com dados e poder computacional suficientes, tende a **superar** o SVM.
- Mais eficiente para conjuntos de treino muito grandes com kernel caro.
- Pesquisa e adoção crescendo mais rápido que SVM na última década.

Ideia-Chave

Em geociências com poucos dados rotulados (ex.: poços, imagens de migração), o SVM costuma ser competitivo ou superior à NN.

Obrigado!

Perguntas e discussão