SiameseFWI: rede neural siamesa para inversão de forma de onda completa

Ernane Ferreira Rocha Junior [1]

Pedro Rêgo Vilar Neto [1]

[1]Programa de Pós-Graduação em Engenharia Elétrica e de Computação (PPGEEC)
Universidade Federal do Rio Grande do Norte (UFRN)

Outubro de 2026

Sumário

1 Introdução

2 Metodologia

3 Resultados

4 Conclusão

5 Referências

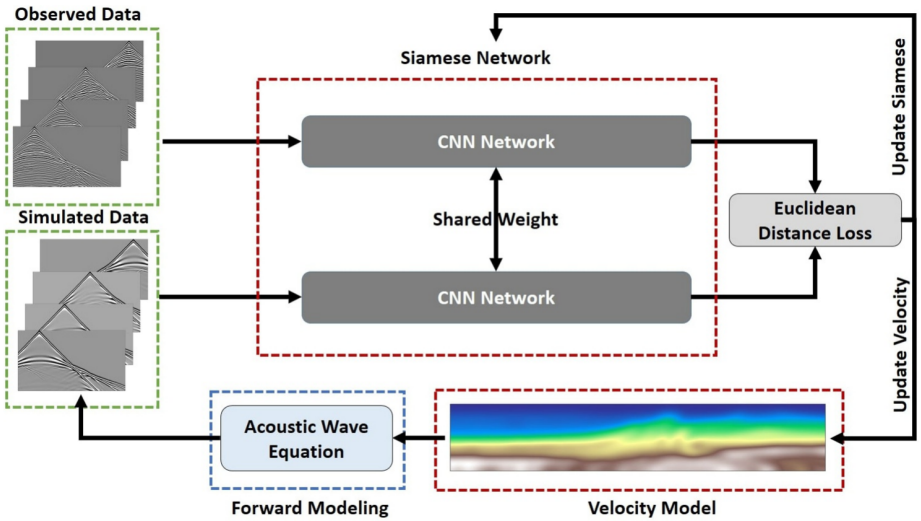
O problema: inversão de forma de onda completa

- **FWI** (*Full Waveform Inversion*) estima o modelo de velocidade da subsuperfície a partir de dados sísmicos registrados na superfície.
- A cada iteração, compara-se o dado simulado com o dado observado e atualiza-se o modelo de velocidade para reduzir essa diferença.
- A qualidade da inversão depende fortemente de como essa diferença (função de *misfit*) é medida.
- O critério mais comum, a norma L_2 ponto a ponto, é sensível a diferenças de fase e leva a mínimos locais (*cycle-skipping*).

Motivação do SiameseFWI

- Trabalhos anteriores propõem funções de *misfit* alternativas: distância de Wasserstein, correlação cruzada, redes adversárias (FWIGAN), redes pré-treinadas por meta-aprendizagem (ML-misfit).
- Essas abordagens ou exigem dados rotulados, ou adicionam custo computacional alto, ou dependem de um treinamento prévio em muitos modelos de velocidade.
- Saad, Harsuko e Alkhalifah (2024) propõem o **SiameseFWI**: uma rede neural siamesa, treinada de forma *self-supervised* durante o próprio processo de FWI, com baixo custo computacional adicional.

Arquitetura geral do SiameseFWI



ıre 1. The framework of the proposed SiameseFWI. The SiameseFWI involves two identical Convolutional Neural ıworks (CNNs) with shared weights, each taking observed and simulated data as inputs. The Euclidean distance measures loss between the CNNs outputs, where the loss is used to optimize both the parameters of the Siamese network and the ıcity model during the full-wave inversion (FWI) process. The acoustic wave equation is used for forward modeling to erate the simulated data during the FWI iteration process. The forward modeling is performed by the Deepwave toolbox, ch operates using the PyTorch library.

- Duas CNNs idênticas, com pesos compartilhados, extraem *features* do dado observado e do dado simulado.
- A distância Euclidiana entre as *features* é a perda do SiameseFWI.
- Essa perda atualiza, ao mesmo tempo, os pesos da rede siamesa **e** o modelo de velocidade.

Teoria: modelagem direta e função de perda

Equação de onda acústica 2D, usada para gerar o dado simulado a cada iteração:

$$\nabla^2 p(r,t) = \frac{1}{v^2(r)} \frac{\partial^2 p(r,t)}{\partial t^2} + s(r,t)\,\delta(r - r_s) \tag{1}$$

Distância Euclidiana entre as *features* extraídas pela rede siamesa, usada como função de perda:

$$E = \sqrt{\sum_{i=0}^{n} \left(C(d_{obs}, \phi) - C(d_{sim}, \phi) \right)^2} \tag{2}$$

- d_{obs} e d_{sim}: dado observado e simulado; C e ϕ: a CNN e seus parâmetros.
- Dois otimizadores Adam separados: um para o modelo de velocidade, outro para a rede siamesa.

A rede CNN da arquitetura siamesa

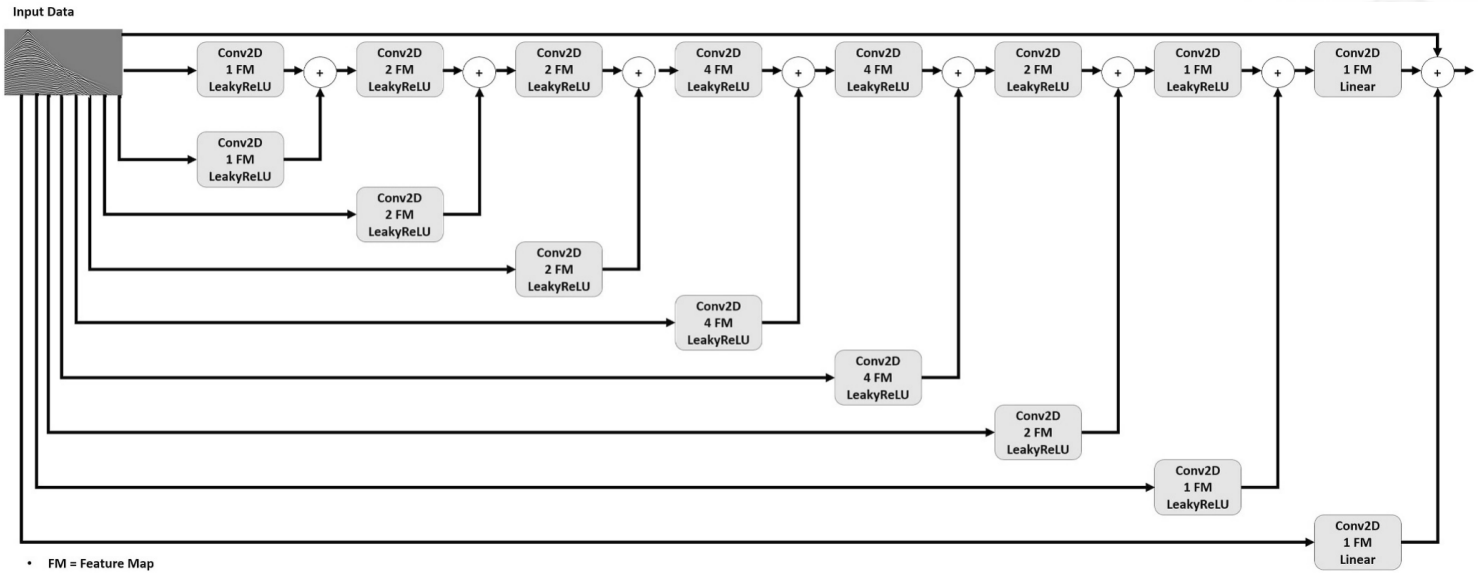


Figure 2. The architecture of the proposed convolutional neural network (CNN) network. The proposed CNN network features eight convolutional layers, each employing a LeakyReLU activation function. A skip connection is incorporated after each convolutional layer, enhancing the learning capacity of the network. The output of the CNN network represents the extracted features from either the observed or simulated data. Both branches of the Siamese network employ a similar CNN

- 8 camadas convolucionais 3×3 com LeakyReLU, exceto a última, linear.
- 8 conexões residuais (*skip connections*), sem camada de *pooling*: o tamanho espacial da entrada é preservado em toda a rede.
- Pesos inicializados aleatoriamente e otimizados ao longo do processo de FWI, sem pré-treinamento.

Modelo sintético Marmousi2

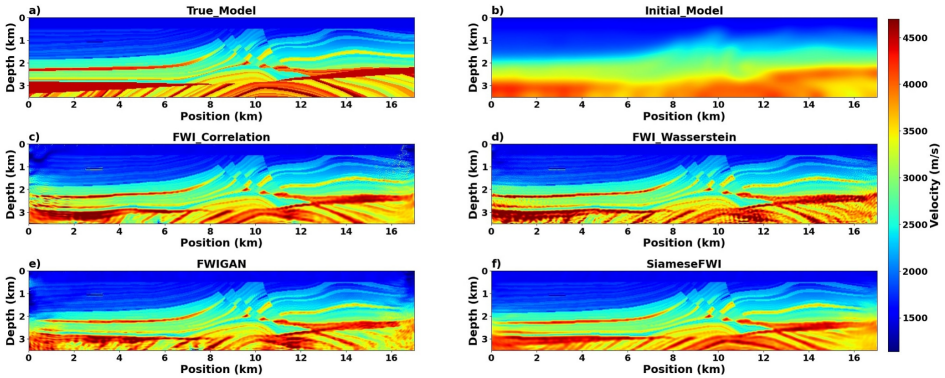
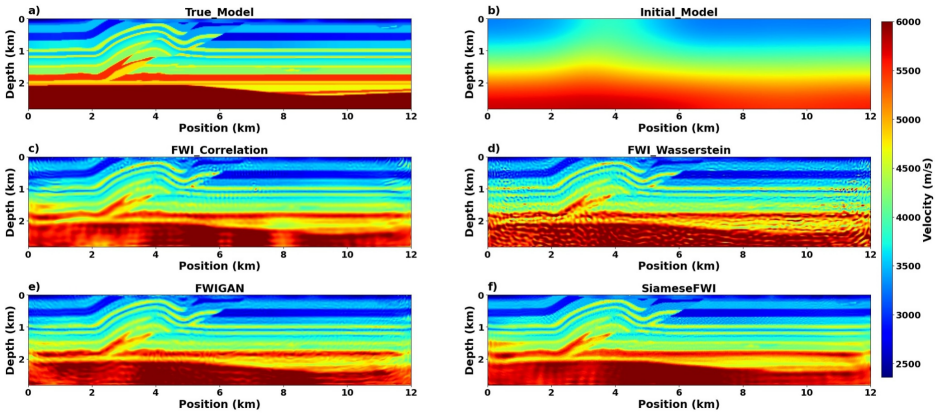


Figure 3. Results comparison for the Marmousi2 model. (a) The true Marmousi2 model. (b) The initial velocity model. The inverted model using (c) cross-correlation loss, (d) Wasserstein loss, (e) FWIGAN, and (f) SiameseFWI.

Método	SNR (dB)
Correlação cruzada	19,18
Wasserstein	19,42
FWIGAN	19,06
SiameseFWI	**22,57**

SiameseFWI obtém o melhor SNR, SSIM e RMSE entre os quatro métodos, com custo de apenas 10%–20% a mais que o FWI convencional.

Modelo sintético Overthrust



Método	SNR (dB)
Correlação cruzada	24,52
Wasserstein	23,25
FWIGAN	25,95
SiameseFWI	**26,98**

Mesmo padrão do Marmousi2: SiameseFWI à frente em SNR e SSIM, enquanto o FWIGAN (outro método baseado em rede neural) é cerca de 6 vezes mais lento.

Dado de campo (Austrália)

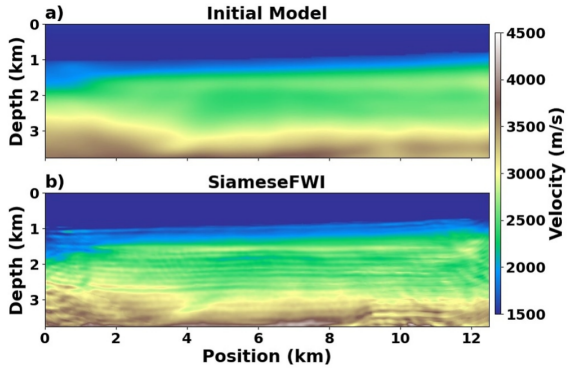


Figure 9. Application of SiameseFWI to the data acquired by CGG in the North Western part of Australia. (a) The initial velocity model. (b) The inverted model using SiameseFWI.

- Dado sísmico marinho real, sem modelo de velocidade verdadeiro conhecido.
- O modelo invertido pelo SiameseFWI ajusta melhor os dados observados que o modelo inicial, sobretudo nos afastamentos maiores entre fonte e receptor.
- Migração reversa no tempo (RTM) com o modelo invertido resolve melhor as interfaces entre 1,5 e 2 km de profundidade.

Robustez do SiameseFWI

- **Ruído:** com ruído branco gaussiano aditivo (SNR do dado de -5 dB), SiameseFWI mantém SNR de 23,48 dB no modelo invertido, contra 19,18 dB da perda de Wasserstein.
- **Modelo inicial impreciso:** mesmo partindo de um modelo inicial linear (sem nenhuma estrutura real), SiameseFWI converge para um modelo próximo ao verdadeiro.
- **Wavelet de fonte desconhecida:** ao estimar a *wavelet* junto com o modelo de velocidade, o método ainda atinge SNR de 24 dB.

Limitações e trabalhos futuros

- Dois otimizadores Adam (rede siamesa e modelo de velocidade) precisam de taxas de aprendizado bem coordenadas entre si.
- Sem camada de *pooling*, o tamanho espacial é preservado em toda a rede: em dados de campo de grande dimensão, isso aumenta o custo de memória e processamento.
- A rede siamesa aprendida em um conjunto de dados não transfere bem para outro: *transfer learning* direto do Overthrust para o Marmousi2 piora o resultado (SNR cai de 22,57 para 20,27 dB).

Conclusão

- O SiameseFWI usa uma rede siamesa *self-supervised*, treinada durante o próprio FWI, para comparar dado observado e simulado em um espaço latente.
- Supera FWI com perdas convencionais (correlação cruzada, Wasserstein) e o FWIGAN, tanto em modelos sintéticos quanto em dado de campo real.
- Alcança esse ganho com apenas 10%–20% de custo computacional extra, e se mantém robusto a ruído e a modelo inicial impreciso.

Referências I

SAAD, O. M.; HARSUKO, R.; ALKHALIFAH, T. SiameseFWI: A deep learning network for enhanced full waveform inversion. *Journal of Geophysical Research: Machine Learning and Computation*, v. 1, n. 1, p. e2024JH000227, 2024.